DHBW Stuttgart

KI-Coding-Agenten in Entwickler-Workflows

Gestaltungsprinzipien und Evidenzgrenzen

Matej Vidakovic · Malik Haase · Sergiu Paculea

Neue Konzepte der Informatik

DHBW Stuttgart

Coding-Agenten sind in der Praxis angekommen

22,20 %

der 128.018 untersuchten GitHub-Projekte nutzen Coding-Agenten (konservative Schätzung; obere Schätzung 28,66 %)[1]

Ein Teil der Entwicklungsarbeit verlagert sich zum Spezifizieren, Überwachen und Prüfen.[2]

Ob das Zeit spart und korrekten Code liefert, zeigen weder Benchmark-Erfolge noch die Zahl erzeugter Pull Requests.[3]

[1] Robbes et al. 2026 · [2] Dhanorkar et al. 2026 · [3] Becker et al. 2025; Wang, Pradel, Liu 2026; Watanabe et al. 2026

FORSCHUNGSFRAGE

DHBW Stuttgart

Welche Gestaltungsprinzipien für Workflows mit KI-Coding-Agenten lassen sich aus aktueller Literatur ableiten, und welche Evidenzgrenzen bestehen für Codequalität und Produktivität?

Vergleichende Synthese entlang dreier Dimensionen

Kontext

Autonomie

Qualitätssicherung

VORGEHEN

DHBW Stuttgart

21 Arbeiten, Evidenzarten getrennt eingeordnet

1

Suche

ACM Digital Library, IEEE Xplore und arXiv, dazu Rückwärtssuche in den Literaturverzeichnissen

2

Auswahl

Ab 2024; mehrschrittig arbeitende, werkzeugnutzende LLM-Agenten; empirische Studie oder System mit Evaluation

3

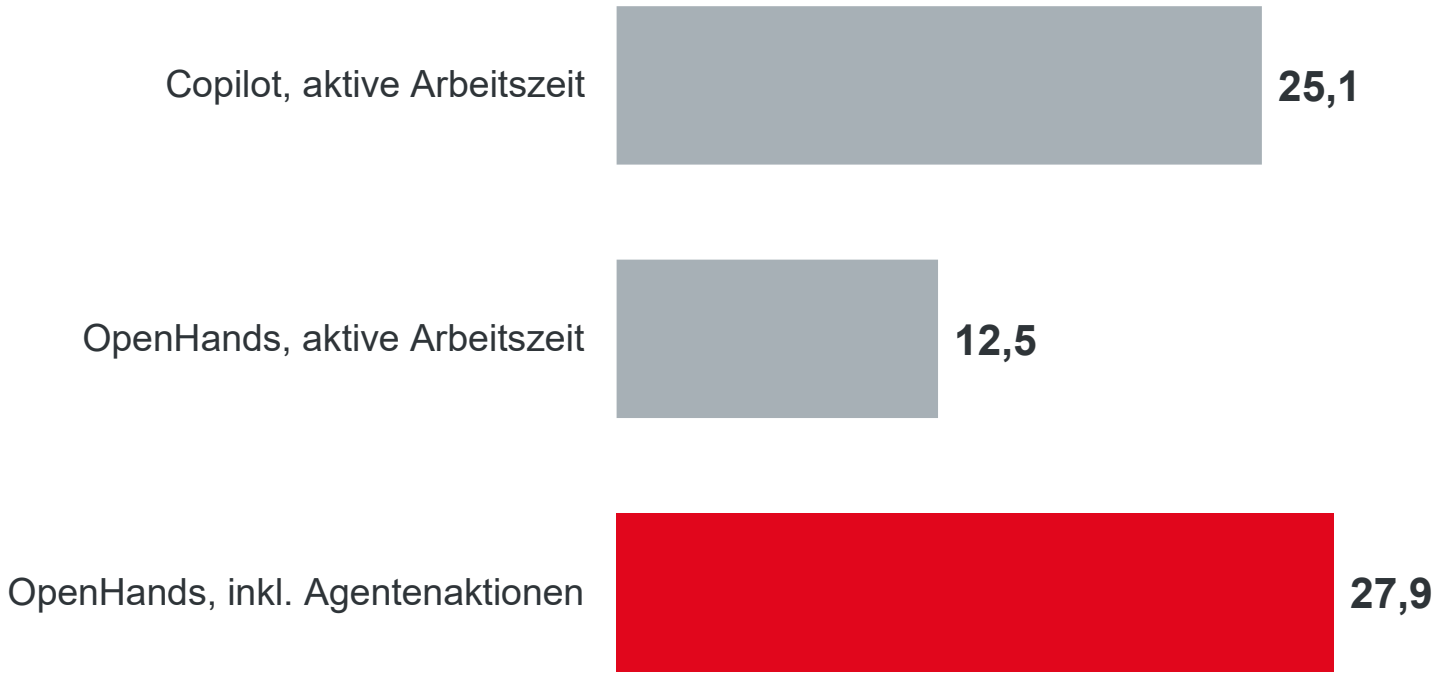
Einordnung

Kontrollierte Vergleiche, Beobachtungen und qualitative Aussagen getrennt; keine studienübergreifenden Effektgrößen

DHBW Stuttgart

Weniger aktive Arbeit heißt nicht kürzere Gesamtdauer

Minuten pro korrekt abgeschlossener Aufgabe (20 Studierende)



FELDEXPERIMENT

+19 %

Bearbeitungszeit bei erlaubter KI-Nutzung. Die Entwickler schätzten dagegen 20 % Zeitersparnis.

Chen et al. 2026 (OpenHands vs. Copilot) · Becker et al. 2025 (16 erfahrene Open-Source-Entwickler)

DHBW Stuttgart

LLM-generierte Kontextdateien kosten mehr, ohne messbar mehr zu lösen

n. s.

Kein signifikanter Gesamteffekt auf die Erfolgsrate gegenüber fehlenden Kontextdateien

+20 / +23 %

Inferenzkosten auf SWE-bench Lite bzw. auf CTXBench

+2,45 / +3,92

Agentenschritte im Mittel, gleiche Zuordnung

Empfehlung der Autoren: nur konkrete, sonst nicht verfügbare Anforderungen ergänzen.

Gloaguen et al. 2026 · n. s. = nicht signifikant

DHBW Stuttgart

Bestandene Tests belegen keine korrekte Lösung

65,4 %

der testbestehenden AutoCodeRover-Patches manuell als korrekt eingestuft (51 von 78)

29,6 %

von 877 testbestehenden Patches weichen im Verhalten von der Referenz ab

45,1 %

der gemergten Claude-Code-PRs wurden vor dem Merge revidiert (214 von 475)

Zhang et al. 2024 · Wang et al. 2026 (SWE-bench Verified) · Watanabe et al. 2026

DHBW Stuttgart

Fünf Prinzipien mit konkreter Handlungsregel

Prinzip	Handlungsregel (eigener Vorschlag)	Begründet durch
P1 Planung gemeinsam prüfen	Bei unklaren Anforderungen Ziel und Akzeptanzkriterien vor der Umsetzung abstimmen	HULA, Interviewstudie [1]
P2 Autonomie nach Risiko staffeln	Sicherheitskritische oder schwer umkehrbare Änderungen menschlich freigeben	Patch-Sicherheit, Aufsicht, Sandbox [2]
P3 Kontext gezielt ergänzen	Fehlende Build-, Test- und Projektanforderungen gezielt ergänzen	Kontextdatei-Studien [3]
P4 Mehrstufig verifizieren	Bestandene Tests durch anforderungsbezogene Prüfungen ergänzen	Linter-Vergleich, Patch-Analysen [4]
P5 Überprüfbar integrieren	Änderungen sachlich abgrenzen und vor dem Merge nachvollziehbar prüfen	PR-Studien [5]

Die Handlungsregeln sind eigene Gestaltungsempfehlungen, keine belegten Wirkungsaussagen

[1] Takerngsaksiri et al. 2025; Dhanorkar et al. 2026 · [2] Sajadi et al. 2025; Dhanorkar et al. 2026; Wang et al. 2025 · [3] Mohsenimofidi et al. 2026; Gloaguen et al. 2026
[4] Yang et al. 2024; Wang, Pradel, Liu 2026; Cemri et al. 2025 · [5] Watanabe et al. 2026; Sajadi et al. 2025

DHBW Stuttgart

Belegt sind Einzelmaßnahmen, nicht der Gesamtworkflow

Kontrolliert belegt

- Linter in SWE-agent: 18 % statt 15 % gelöste Aufgaben
- Agent statt Copilot: 60 % statt 25 % korrekt abgeschlossen
- Geänderte ChatDev-Topologie: 40,6 % statt 25,0 %, mehrere Änderungen zugleich

Offen

- Wirkung der fünf Prinzipien als Gesamtworkflow
- Übertragbarkeit über Python-Repositories hinaus
- Langfristige Wartbarkeit und menschlicher Prüfaufwand

Yang et al. 2024 · Chen et al. 2026 · Cemri et al. 2025 · Jimenez et al. 2024

DHBW Stuttgart

Zusätzliche Prüfung lohnt sich nur, wenn sie genug Defekte findet

Vorschlag: kontrollierter Vergleich mit und ohne menschliche Planfreigabe, bei gleichem Agenten, Modell und Budget.

GETRENNT MESSEN

- **Funktionale Defekte**
- **Aktive Arbeitszeit**
- **Gesamtdauer**
- **Review-Aufwand**

FAZIT

DHBW Stuttgart

Konkrete Empfehlungen sind möglich, ein allgemeiner Produktivitätsgewinn ist nicht belegt

Ableitbar

Fünf begründete Prinzipien: Planung, Autonomie, Kontext, Verifikation, Integration

Getrennt bewerten

Aktive Arbeitszeit, Gesamtdauer, Testbestehen und funktionale Korrektheit

Nötig

Kontrollierte Vergleiche einzelner Entscheidungen und langfristige Messungen

DHBW Stuttgart

Quellen

Becker et al. (2025): Measuring the impact of early-2025 AI on experienced open-source developer productivity. arXiv:2507.09089

Cemri et al. (2025): Why do multi-agent LLM systems fail? NeurIPS

Chen et al. (2026): Code with me or for me? CHI ’26

Dhanorkar et al. (2026): Human oversight of agentic systems in practice. arXiv:2606.05391

Gloaguen et al. (2026): Evaluating AGENTS.md. ICLR 2026 Workshop MemAgents

Jimenez et al. (2024): SWE-bench. ICLR

Mohsenimofidi et al. (2026): Context engineering for AI agents in open-source software. MSR

Robbes et al. (2026): Agentic much? Adoption of coding agents on GitHub. ACM TOSEM

Sajadi et al. (2025): How safe are AI-generated patches? arXiv:2507.02976

Takerngsaksiri et al. (2025): Human-in-the-loop software development agents. ICSE-SEIP

Wang et al. (2025): OpenHands: An open platform for AI software developers. ICLR

Wang, Pradel, Liu (2026): Are „solved issues“ in SWE-bench really solved correctly? ICSE

Watanabe et al. (2026): On the use of agentic coding. ACM TOSEM

Yang et al. (2024): SWE-agent. NeurIPS

Zhang et al. (2024): AutoCodeRover. ISSTA

Vollständige Angaben zu allen 21 Arbeiten im Paper